

# Epigenetische PCA: Latente Dimensionen menschlicher epigenetischer Variation

Cheyenne M. Lühning

## Zusammenfassung

Dieses Projekt untersucht, ob sich epigenetische Signalprofile verschiedener Biosamples durch wenige orthogonale Muster annähern lassen. Dazu werden Histon-Signaltracks des Roadmap-Epigenomics-Projekts auf gemeinsame Genomfenster abgebildet und in einer Stichproben-Merkmalismatrix zusammengefasst. Nach einer logarithmischen Transformation und einer Merkmalsstandardisierung wird die Hauptkomponentenanalyse (PCA) mit drei numerischen Verfahren berechnet: einer Implementierung mit scikit-learn, einer dualen Kovarianzzerlegung und einer Singulärwertzerlegung. Verglichen werden die Eigenwerte, die erklärte Varianz und der Rekonstruktionsfehler. Die Hauptkomponenten beschreiben statistische Variationsrichtungen der ausgewählten Daten; sie beweisen weder kausale Regulationsmechanismen noch eine biologische Funktion einzelner Genomfenster.

## 1 Einleitung

Epigenetische Messungen beschreiben regulatorische Markierungen, ohne die DNA-Sequenz selbst zu verändern. In diesem Projekt werden Histon-Signaltracks analysiert. Ein Signaltrack ordnet Genomabschnitten numerische Werte zu. Diese Werte sind assaybasierte Messsignale und keine unmittelbaren Messungen der Genexpression.

Da ein Track viele Genompositionen abdeckt, entstehen pro Biosample zahlreiche Merkmale. Die Hauptkomponentenanalyse (PCA) sucht nach wenigen linearen Richtungen, entlang derer die Messungen besonders stark variieren. Die Grundidee ist dabei eine Kompression: Statt jede einzelne Messung separat zu betrachten, beschreibt man ein Biosample durch seine Koordinaten in einem niedrigdimensionalen Unterraum.

Anschaulich kann man sich jedes Biosample als Punkt in einem hochdimensionalen Raum vorstellen. Jedes Genomfenster bildet eine Koordinatenrichtung. PCA dreht das Koordinatensystem so, dass die erste neue Achse möglichst viel Streuung der Punkte erfasst. Die zweite Achse erfasst möglichst viel der verbleibenden Streuung und steht senkrecht auf der ersten. Weitere Achsen werden entsprechend ergänzt.

Die Ergebnisse gelten für die ausgewählten Biosamples, die Histonmarkierung, die Fenstergröße und die verwendete Vorverarbeitung. Andere Entscheidungen können zu anderen Hauptkomponenten führen.

## 2 Daten als Matrix

Es seien  $n$  Biosamples und  $p$  Genomfenster-Merkmale gegeben. Die Messungen lassen sich als Matrix

$$X \in \mathbb{R}^{n \times p}$$

darstellen. Zeile  $i$  entspricht dem  $i$ -ten Biosample und Spalte  $j$  einem Merkmal. Ein Merkmal ist eine Kombination aus Histonmarkierung und Genomfenster.

Im Projekt stammen die Signaltracks aus dem öffentlichen Roadmap-Epigenomics-Datensatz. Die Tracks werden auf gemeinsame Fenster von ungefähr 100 kb zusammengefasst. Nicht berichtete bigWig- Intervalle werden beim Zusammenfassen als Null behandelt. Die Standardauswahl des Workflows umfasst 17 EIDs und die Histonmarkierung H3K4me3; die Auswahl kann für explorative Analysen angepasst werden.

### 3 Vorverarbeitung

Vor der PCA werden die Messwerte transformiert und standardisiert. Zunächst werden nicht-endliche Werte als fehlend behandelt. Fehlende Werte werden durch den Median des jeweiligen Merkmals ersetzt; falls danach noch Werte fehlen, werden sie durch Null ersetzt. Negative Signale werden auf Null begrenzt. Auf die resultierenden Werte wird die Transformation

$$Y_{ij} = \log(1 + X_{ij})$$

angewendet.

Die logarithmische Transformation komprimiert große Werte stärker als kleine. Das ist nützlich, wenn einzelne sehr große Signale die Varianz dominieren würden. Sie erhält die Ordnung nichtnegativer Werte, verringert aber den Abstand zwischen ihnen.

Für jedes Merkmal  $j$  werden anschließend Mittelwert und Stichproben-Standardabweichung berechnet:

$$\bar{Y}_j = \frac{1}{n} \sum_{i=1}^n Y_{ij}, \quad s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_{ij} - \bar{Y}_j)^2}.$$

Merkmale mit  $s_j = 0$  sind konstant und enthalten keine Variation zwischen den Biosamples; sie werden entfernt. Für die übrigen Merkmale wird

$$Z_{ij} = \frac{Y_{ij} - \bar{Y}_j}{s_j}$$

gebildet. Damit hat jede Spalte der Matrix  $Z$  Mittelwert Null und Stichproben-Standardabweichung Eins.

Diese Standardisierung bedeutet, dass die PCA nicht mehr direkt auf den Kovarianzen der logarithmierten Signale arbeitet, sondern auf deren Korrelationsstruktur. Merkmale mit ursprünglich kleiner Signalvarianz können dadurch ähnlich stark gewichtet werden wie Merkmale mit großer Signalvarianz. Das ist eine wissenschaftliche Modellierungsentscheidung und kann auch verdrauschte Merkmale verstärken.

### 4 PCA als Varianzmaximierung

Die Matrix  $Z \in \mathbb{R}^{n \times p}$  ist spaltenzentriert. Ihre Stichproben-Kovarianzmatrix ist

$$C = \frac{1}{n-1} Z^T Z.$$

Die Matrix  $C$  ist symmetrisch, denn

$$C^T = \frac{1}{n-1} (Z^T Z)^T = \frac{1}{n-1} Z^T Z = C.$$

Außerdem ist sie positiv semidefinit: Für jeden Vektor  $v \in \mathbb{R}^p$  gilt

$$v^T C v = \frac{1}{n-1} v^T Z^T Z v = \frac{1}{n-1} \|Zv\|_2^2 \geq 0.$$

Daraus folgt, dass alle Eigenwerte von  $C$  nichtnegativ sind.

#### 4.1 Warum maximiert PCA die Varianz?

Eine Richtung im Merkmalsraum wird durch einen Einheitsvektor  $v \in \mathbb{R}^p$  beschrieben. Die Projektion der Biosamples auf diese Richtung ergibt den Scorevektor

$$t = Zv \in \mathbb{R}^n.$$

Da die Spalten von  $Z$  zentriert sind, ist auch  $t$  zentriert. Die Stichprobenvarianz der Scores ist deshalb

$$\text{Var}(Zv) = \frac{1}{n-1} \|Zv\|_2^2 = v^\top C v.$$

Die erste Hauptkomponente ist also die Einheitsrichtung  $v$ , für die  $v^\top C v$  maximal wird.

Die Bedingung  $\|v\|_2 = 1$  ist wesentlich: Ohne sie könnte man jede Richtung beliebig strecken und dadurch den Wert von  $v^\top C v$  beliebig vergrößern. Gesucht wird eine Richtung, nicht eine beliebig skalierte Version davon.

**Aussage 1** (Eigenwertgleichung für eine Hauptkomponente). *Ein Extremum von  $v^\top C v$  unter der Nebenbedingung  $v^\top v = 1$  erfüllt*

$$Cv = \lambda v$$

*für einen Skalar  $\lambda$ . Das globale Maximum wird durch einen Eigenvektor zum größten Eigenwert von  $C$  erreicht.*

*Beweis.* Wir verwenden den Lagrange-Multiplikator  $\lambda$  und betrachten

$$L(v, \lambda) = v^\top C v - \lambda(v^\top v - 1).$$

Da  $C$  symmetrisch ist, gilt

$$\nabla_v(v^\top C v) = 2Cv, \quad \nabla_v(v^\top v) = 2v.$$

Die Stationaritätsbedingung lautet daher

$$\nabla_v L = 2Cv - 2\lambda v = 0,$$

also

$$Cv = \lambda v.$$

Ein stationärer Vektor muss somit ein Eigenvektor von  $C$  sein.

Warum gehört das Maximum zum größten Eigenwert? Nach dem Spektralsatz besitzt die symmetrische Matrix  $C$  eine Orthonormalbasis aus Eigenvektoren  $q_1, \dots, q_p$  mit Eigenwerten  $\lambda_1 \geq \dots \geq \lambda_p$ . Schreibe einen beliebigen Einheitsvektor als

$$v = \sum_{j=1}^p a_j q_j, \quad \sum_{j=1}^p a_j^2 = 1.$$

Dann ist

$$v^\top C v = \sum_{j=1}^p \lambda_j a_j^2 \leq \lambda_1 \sum_{j=1}^p a_j^2 = \lambda_1.$$

Gleichheit wird erreicht, wenn  $v$  im Eigenraum zum größten Eigenwert liegt. Damit ist die maximale Varianz gleich  $\lambda_1$ .  $\square$

Der Ausdruck  $v^\top C v$  ist somit ein gewichteter Mittelwert der Eigenwerte, wobei die Gewichte  $a_j^2$  nichtnegativ sind und sich zu Eins summieren. Die Maximierung wählt die Richtung aus, die möglichst viel Gewicht auf große Eigenwerte legt.

## 4.2 Orthogonalität der Hauptkomponenten

Für zwei Eigenvektoren  $u$  und  $v$  einer symmetrischen Matrix  $C$  mit verschiedenen Eigenwerten  $\lambda$  und  $\mu$  gilt

$$Cu = \lambda u, \quad Cv = \mu v.$$

Wegen der Symmetrie von  $C$  erhalten wir

$$\lambda u^T v = (Cu)^T v = u^T Cv = \mu u^T v.$$

Also gilt

$$(\lambda - \mu)u^T v = 0.$$

Ist  $\lambda \neq \mu$ , folgt  $u^T v = 0$ : Die Eigenvektoren sind orthogonal. Bei mehrfachen Eigenwerten kann innerhalb des zugehörigen Eigenraums eine Orthonormalbasis gewählt werden. Daher lassen sich die Hauptkomponenten orthonormal anordnen.

## 4.3 Eigenwerte, Scores und erklärte Varianz

Die PCA-Richtungen erfüllen

$$Cv_k = \lambda_k v_k, \quad \|v_k\|_2 = 1, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

Die Scores der Biosamples auf der  $k$ -ten Hauptkomponente sind

$$t_k = Zv_k.$$

Ihre Stichprobenvarianz ist

$$\frac{1}{n-1} t_k^T t_k = \frac{1}{n-1} v_k^T Z^T Z v_k = v_k^T C v_k = \lambda_k.$$

Damit ist der Eigenwert  $\lambda_k$  genau die Varianz der Scores auf der  $k$ -ten Hauptkomponente.

Die Gesamtvarianz über alle Merkmale lässt sich mit der Spur der Kovarianzmatrix ausdrücken:

$$\text{tr}(C) = \sum_{j=1}^p C_{jj} = \sum_{k=1}^q \lambda_k = \frac{\|Z\|_F^2}{n-1},$$

wobei  $q = \text{rang}(Z)$  die Anzahl nichtverschwindender Hauptkomponenten ist. Die Gleichheit zwischen Spur und Eigenwertsumme folgt aus der Diagonalisierbarkeit der symmetrischen Matrix  $C$ .

Der Anteil der Gesamtvarianz, der durch Komponente  $k$  erklärt wird, ist

$$r_k = \frac{\lambda_k}{\sum_{j=1}^q \lambda_j}.$$

Der kumulative Anteil der ersten  $k$  Komponenten ist

$$R_k = \sum_{j=1}^k r_j.$$

Diese Größen beantworten die Frage, wie viel der beobachteten Variation in den ersten Komponenten zusammengefasst wird.

Da  $Z$  zentriert ist, sind ihre Zeilen linear abhängig: Die Summe der Zeilen ist der Nullvektor. Somit gilt

$$q = \text{rang}(Z) \leq \min(n-1, p).$$

Insbesondere kann die Zahl nichttrivialer Hauptkomponenten nicht größer als  $n-1$  sein.

## 5 Drei numerische Berechnungsverfahren

Im Projekt wird die PCA mit drei numerischen Verfahren berechnet. Der Vergleich dient dazu, Implementierungen zu prüfen und ihre mathematische Äquivalenz sichtbar zu machen.

### 5.1 PCA mit scikit-learn

Die erste Berechnung verwendet scikit-learn mit vollständiger Singularwertzerlegung. Sie liefert Scores, Ladungen, Eigenwerte und erklärte Varianzanteile. Die vollständige Zerlegung wird verwendet, damit die Resultate direkt mit den beiden selbst implementierten Verfahren verglichen werden können.

### 5.2 Duale Kovarianzzerlegung

Die Kovarianzmatrix  $C$  hat die Dimension  $p \times p$ . Wenn  $p$  viel größer als  $n$  ist, kann es rechnerisch günstiger sein, die kleinere Matrix

$$G = \frac{1}{n-1} Z Z^T \in \mathbb{R}^{n \times n}$$

zu zerlegen. Sie wird duale Kovarianz- oder Gram-Matrix genannt.

Sei  $u_k$  ein normierter Eigenvektor von  $G$  zum positiven Eigenwert  $\lambda_k$ :

$$G u_k = \lambda_k u_k.$$

Dann kann der zugehörige Eigenvektor im Merkmalsraum durch

$$v_k = \frac{Z^T u_k}{\sqrt{(n-1)\lambda_k}}$$

rekonstruiert werden.

Die Normierung im Nenner lässt sich herleiten:

$$\|Z^T u_k\|_2^2 = u_k^T Z Z^T u_k = (n-1) u_k^T G u_k = (n-1) \lambda_k.$$

Damit gilt  $\|v_k\|_2 = 1$ . Außerdem folgt

$$C v_k = \frac{Z^T Z Z^T u_k}{(n-1) \sqrt{(n-1)\lambda_k}} = \lambda_k v_k.$$

Der Eigenvektor der dualen Matrix liefert also denselben Eigenwert und bestimmt nach Rücktransformation eine Hauptkomponente im Merkmalsraum.

### 5.3 Singularwertzerlegung

Die dritte Berechnung verwendet die dünne Singularwertzerlegung

$$Z = U \Sigma V^T.$$

Die Spalten von  $U$  und  $V$  sind orthonormal. Die Diagonaleinträge  $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$  der Matrix  $\Sigma$  heißen Singularwerte.

Setzt man die Zerlegung in die Kovarianzmatrix ein, erhält man

$$C = \frac{1}{n-1} Z^T Z = \frac{1}{n-1} V \Sigma^T U^T U \Sigma V^T = V \frac{\Sigma^2}{n-1} V^T,$$

weil  $U^T U = I$ . Daher gilt

$$\lambda_k = \frac{\sigma_k^2}{n-1}.$$

Die Spalten  $v_k$  von  $V$  sind die Hauptachsen. Ihre Scores ergeben sich direkt aus

$$t_k = Z v_k = \sigma_k u_k.$$

Damit wird die Übereinstimmung zwischen Kovarianzzerlegung und SVD sichtbar: Beide liefern dieselben Eigenwerte und Hauptachsen. Die SVD vermeidet, dass die Kovarianzmatrix explizit gebildet werden muss. Das kann numerisch vorteilhaft sein, da die Bildung von  $Z^T Z$  die Konditionierung verschlechtern kann.

Das Vorzeichen eines Eigenvektors ist nicht eindeutig. Wenn  $v_k$  durch  $-v_k$  ersetzt wird, ändern sich auch die Scores von  $t_k$  zu  $-t_k$ , während die repräsentierte Achse und die Rekonstruktion gleich bleiben. Deshalb sollte man beim Vergleich numerischer PCA-Verfahren nicht nur die Vorzeichen einzelner Ladungen vergleichen.

## 6 Projektion und Rekonstruktion

Die ersten  $k$  Ladungsvektoren werden zu einer Matrix zusammengefasst:

$$V_k = [v_1, \dots, v_k] \in \mathbb{R}^{p \times k}, \quad V_k^T V_k = I_k.$$

Die Matrix

$$P_k = V_k V_k^T$$

ist die orthogonale Projektion auf den von diesen Komponenten aufgespannten Unterraum. Tatsächlich gilt

$$P_k^T = P_k \quad \text{und} \quad P_k^2 = V_k (V_k^T V_k) V_k^T = P_k.$$

Symmetrie und Idempotenz sind die charakteristischen Eigenschaften eines orthogonalen Projektors.

Die Projektion der Daten auf diesen Unterraum wird durch

$$T_k = Z V_k$$

beschrieben. Multipliziert man die Scores zurück mit den Ladungsvektoren, erhält man die Rekonstruktion

$$\hat{Z}_k = T_k V_k^T = Z V_k V_k^T = Z P_k.$$

Die Rekonstruktion nimmt also die Koordinaten der Daten im ausgewählten Unterraum und bildet daraus wieder Vektoren im ursprünglichen Merkmalsraum.

### 6.1 Warum ist die Projektion die nächstgelegene Darstellung?

Für einen einzelnen Datenvektor  $z$  zerlegt die orthogonale Projektion diesen in

$$z = z P_k + z(I - P_k).$$

Der erste Summand liegt im gewählten Unterraum; der zweite steht senkrecht auf diesem Unterraum. Da die beiden Summanden orthogonal sind, gilt nach dem Satz des Pythagoras

$$\|z\|_2^2 = \|z P_k\|_2^2 + \|z(I - P_k)\|_2^2.$$

Jede andere Approximation von  $z$  innerhalb desselben Unterraums hat einen zusätzlichen Anteil in einer Richtung des Unterraums und kann daher den Abstand zu  $z$  nicht verkleinern. Die orthogonale Projektion ist somit die nächstgelegene Approximation in diesem Unterraum.

PCA wählt unter allen  $k$ -dimensionalen Unterräumen gerade denjenigen, der den gesamten quadratischen Projektionsfehler minimiert. Dazu maximiert sie die Summe der projizierten Varianzen. Wenn  $W$  eine beliebige Matrix mit  $k$  orthonormalen Spalten ist, beträgt die darin eingefangene quadratische Streuung

$$\|ZW\|_F^2 = \text{tr}(W^\top Z^\top ZW) = (n-1) \text{tr}(W^\top CW).$$

Diese Größe ist maximal, wenn die Spalten von  $W$  zu den Eigenvektoren mit den  $k$  größten Eigenwerten gehören. Das ist das Variationsprinzip hinter der Wahl der ersten  $k$  Hauptkomponenten.

**Aussage 2** (Minimaler quadratischer Rekonstruktionsfehler). *Die Projektion auf die ersten  $k$  PCA-Richtungen minimiert den quadratischen Rekonstruktionsfehler unter allen linearen Unterräumen der Dimension  $k$ . Für die PCA-Rekonstruktion gilt*

$$\|Z - \hat{Z}_k\|_F^2 = \sum_{j>k} \sigma_j^2 = (n-1) \sum_{j>k} \lambda_j.$$

*Beweis.* Aus der Singulärwertzerlegung

$$Z = \sum_{j=1}^q \sigma_j u_j v_j^\top$$

besteht die rank- $k$ -PCA-Rekonstruktion aus den ersten  $k$  Summanden:

$$\hat{Z}_k = \sum_{j=1}^k \sigma_j u_j v_j^\top.$$

Der Fehler ist daher

$$Z - \hat{Z}_k = \sum_{j=k+1}^q \sigma_j u_j v_j^\top.$$

Die Matrizen  $u_j v_j^\top$  sind bezüglich des Frobenius-Skalarprodukts orthonormal. Denn

$$\langle u_i v_i^\top, u_j v_j^\top \rangle_F = (u_i^\top u_j)(v_i^\top v_j) = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Somit addieren sich die quadrierten Normen der verbleibenden Summanden:

$$\|Z - \hat{Z}_k\|_F^2 = \sum_{j=k+1}^q \sigma_j^2.$$

Mit  $\sigma_j^2 = (n-1)\lambda_j$  folgt die zweite Gleichheit. Dass kein anderer  $k$ -dimensionaler Unterraum einen kleineren Gesamtfehler erreicht, folgt aus dem Variationsprinzip: Der größte mögliche Anteil der quadratischen Streuung wird durch die  $k$  größten Eigenwerte erfasst.  $\square$

Der im Projekt verwendete relative Rekonstruktionsfehler ist

$$e_k = \frac{\|Z - \hat{Z}_k\|_F}{\|Z\|_F}.$$

Aus der vorherigen Aussage folgt für  $\|Z\|_F > 0$

$$e_k = \sqrt{\frac{\sum_{j>k} \lambda_j}{\sum_{j=1}^q \lambda_j}}.$$

Der Fehler misst, wie viel standardisierte quadratische Streuung bei einer Approximation mit  $k$  Komponenten verloren geht. Er ist kein Maß für die biologische Güte oder kausale Aussagekraft der Komponenten.

## 7 Effektive Dimension

Zusätzlich wird eine effektive Dimension aus dem Eigenwertspektrum berechnet:

$$d_{\text{eff}} = \frac{\left(\sum_{j=1}^q \lambda_j\right)^2}{\sum_{j=1}^q \lambda_j^2}.$$

Sie beschreibt, wie gleichmäßig die Gesamtvarianz über die Komponenten verteilt ist.

**Lemma 1** (Grenzen der effektiven Dimension). *Wenn mindestens ein Eigenwert positiv ist, gilt*

$$1 \leq d_{\text{eff}} \leq q.$$

*Sind alle  $q$  Eigenwerte gleich groß und positiv, so ist  $d_{\text{eff}} = q$ . Dominiert ein einzelner Eigenwert die übrigen, liegt  $d_{\text{eff}}$  näher bei 1.*

*Beweis.* Da alle Eigenwerte nichtnegativ sind,

$$\left(\sum_{j=1}^q \lambda_j\right)^2 = \sum_{j=1}^q \lambda_j^2 + 2 \sum_{i<j} \lambda_i \lambda_j \geq \sum_{j=1}^q \lambda_j^2.$$

Nach Division durch  $\sum_j \lambda_j^2 > 0$  folgt  $d_{\text{eff}} \geq 1$ .

Nach der Cauchy-Schwarz-Ungleichung gilt

$$\left(\sum_{j=1}^q \lambda_j\right)^2 \leq q \sum_{j=1}^q \lambda_j^2.$$

Division durch  $\sum_j \lambda_j^2$  ergibt  $d_{\text{eff}} \leq q$ . Sind alle Eigenwerte gleich  $\lambda > 0$ , ergibt Einsetzen

$$d_{\text{eff}} = \frac{(q\lambda)^2}{q\lambda^2} = q.$$

□

Die effektive Dimension ist eine kontinuierliche Kennzahl der Eigenwertverteilung. Sie ist weder automatisch die Zahl von Komponenten, die für eine bestimmte Fehlertoleranz benötigt wird, noch eine Aussage darüber, wie viele biologische Mechanismen existieren.

## 8 Bezug zu Begriffen und Ergebnissen aus LA2

Die folgenden Bezeichnungen beziehen sich auf mein LA2-Skript. Die Nummerierung wird so wiedergegeben, wie sie dort erscheint. Unnummerierte Begriffseinträge werden ausdrücklich nicht mit einer Nummer versehen.

- **Eigenwert und Eigenvektor** (Abschnitt 33, unnummerierter Begriffseintrag): Der Eintrag erklärt die Bedingung  $Av = \lambda v$  für einen Eigenvektor  $v$  zum Eigenwert  $\lambda$ . Diese Begriffe werden für das Eigenwertproblem der Kovarianzmatrix verwendet.
- **Definition 33.5: Eigenraum, geometrische Vielfachheit**: Diese Definition beschreibt den Eigenraum und seine Dimension. Sie ergänzt den Eigenwertbegriff, ist aber nicht selbst die Definition eines Eigenwerts.
- **Satz 34.3: Kriterien für die Diagonalisierbarkeit einer Matrix**: Der Satz behandelt die Existenz einer Eigenbasis. Für die PCA ist darüber hinaus die Symmetrie der Kovarianzmatrix wichtig, da sie eine orthonormale Wahl der Eigenvektoren ermöglicht.
- **Definition 39.1: Symmetrieeigenschaften**: Die Definition umfasst unter anderem die Symmetrie einer Bilinearform. Für die Kovarianzmatrix zeigt sich die entsprechende Symmetrie unmittelbar durch  $C^T = C$ .
- **Innenprodukt und Orthogonalität** (unnummerierte Begriffseinträge im Skript): Diese Begriffe geben der Bedingung  $u^T v = 0$  ihre geometrische Bedeutung.
- **Satz 40.3: Pythagoras**: Dieser Satz begründet die Zerlegung der quadratischen Norm in Beiträge orthogonaler Vektoren und unterstützt die Interpretation des Projektionsfehlers.
- **Lemma 40.8: Orthogonalbasis**: Das Lemma stellt den Zusammenhang zwischen einer Orthogonalbasis und einer diagonalen Darstellung her. Es passt zur Beschreibung orthogonaler Hauptkomponenten.

Die Herleitungen in dieser Ausarbeitung wenden diese Begriffe auf die Kovarianzmatrix der vorverarbeiteten Projektdaten an. Die drei Implementierungen der PCA sind dagegen Berechnungsverfahren des Projekts und keine nummerierten Sätze oder Definitionen aus dem LA2-Skript.

## 9 Ergebnisse und statistische Einordnung

Die tatsächlichen Resultate hängen von den heruntergeladenen Tracks, der Sample-Auswahl, der Histonmarkierung und den Verarbeitungseinstellungen ab. Nach einem Lauf erstellt der Workflow Tabellen zu Scores, Ladungen, erklärter Varianz und Rekonstruktionsfehlern. Er erzeugt außerdem Abbildungen, Diagnosen und einen datenabhängigen Ergebnisbericht.

Metadatenkategorien wie `GROUP`, `ANATOMY` und `STD_NAME` können deskriptiv mit den Scores verglichen werden. Eine mögliche Zusammenfassung für eine Komponente  $t_i$  und Gruppen  $g$  ist

$$\eta^2 = \frac{\sum_g n_g (\bar{t}_g - \bar{t})^2}{\sum_i (t_i - \bar{t})^2},$$

wobei  $n_g$  die Größe der Gruppe  $g$ ,  $\bar{t}_g$  ihr mittlerer Score und  $\bar{t}$  der Gesamtmittelwert ist. Der Zähler beschreibt die Variation zwischen den Gruppen; der Nenner beschreibt die Gesamtvariation. Ein hoher Wert zeigt, dass die Scores in dieser Stichprobe mit den Metadatenkategorien zusammenhängen. Er ist jedoch kein Kausalitätsnachweis und für sich allein kein statistischer Signifikanztest.

Vor der Ausführung des Workflows werden hier keine empirischen Varianzanteile, effektiven Dimensionen oder biologischen Ergebnisse behauptet. Eine Interpretation muss sich auf die für den konkreten Lauf erzeugten Resultate beziehen.

## 10 Interpretationsgrenzen

PCA findet orthogonale Richtungen großer linearer Varianz. Sie optimiert nicht die Trennung vorgegebener Zelltypen und weist keine kausalen Regulationsmechanismen nach. Große Ladungsbeträge zeigen, dass ein Merkmal stark mit einer Hauptkomponentenrichtung verbunden ist; sie beweisen nicht, dass das Genomfenster eine bestimmte biologische Funktion verursacht.

Batch-Effekte, Unterschiede zwischen Spendern, Zellmischungen, Assay-Qualität und weitere biologische oder technische Faktoren können die Hauptkomponenten beeinflussen. Auch die Standardisierung und Logarithmierung verändern, welche Unterschiede in den Daten betont werden. Deshalb sollten die Ergebnisse gemeinsam mit der Sample-Auswahl, den Vorverarbeitungsschritten und den Rohsignal-Zusammenfassungen interpretiert werden.

## 11 Zusammenfassung

Das Projekt bildet epigenetische Signaltracks auf eine Sample-Merkmalismatrix ab, transformiert und standardisiert deren Merkmale und analysiert die resultierende Matrix mit PCA. Die mathematische Herleitung zeigt, dass die Hauptkomponenten Eigenvektoren der Kovarianzmatrix sind, die nacheinander möglichst viel Varianz erfassen. Über die Singulärwertzerlegung lässt sich dieselbe Zerlegung direkt aus der Datenmatrix gewinnen. Die ersten  $k$  Komponenten bilden zugleich den  $k$ -dimensionalen Unterraum mit minimalem quadratischem Rekonstruktionsfehler. Die resultierenden Achsen sind eine kompakte statistische Beschreibung der ausgewählten Messdaten; ihre biologische Interpretation erfordert zusätzliche Validierung.